SAS Text Analytics findet Zusammenhänge in Texten – Ergebnisse eines Selbstversuchs

Secretary Control of the Control of


21. KSFE, Krefeld, 9.-10. März 2017 Gerhard Svolba

Die Vortragsfolien sind online → Google: Gerhard SAS Samples



SAS Analytik Plattform

Unterschiedliche Layer aus konzeptioneller Sicht



SAS Analytik Plattform

Advanced Analytic Layer

Business Intelligence











Statistical Analysis

Forecasting

Text Analytics

Datenmanagement









SAS® Contextual Analysis


EIN BLICK IN DIE LÖSUNGSBESCHREIBUNG

- Was macht die Lösung?
 - Es erlaubt große Sammlungen von Text-Dokumenten zu analysieren, Sentiments zu identifizieren und robuste Modelle zur Kategorisierung und Extraktion von Inhalten zu erstellen.
- Wie funktioniert das?
 - Kombination von automatischer Erkennung, Machine-Learning Methoden, Linguistischer Regeln und Experten-Input zur Entwicklungen eines Kategorisierungs/Extraktions-Modells
 - Automatische Identifikation von Themen in den Dokumenten, Definition von Kategorien und Überarbeitungen durch den Text-Analysten
 - Interaktives Testen und visuelle Exploration über ein HTML5-Browser Interface mit Wizards und Contextsensitiver Hilfe.
- Wie integriert sich SAS® Contextual Analysis in das SAS Portfolio?
 - Integrierter Teil der SAS Plattform (SAS Metadata Server, ...)
 - (Mögliche) Ergänzung zum SAS Text Miner
 - Ergebnis-Darstellung mit SAS Visual Analytics, Weiterwendung in SAS Analytik Produkten



SAS® Contextual Analysis


PROZESSFLUSS UND ÖKO-SYSTEM





Der Selbstversuch

DIE AUSGANGSBASIS: 2 BÜCHER VON SAS-PRESS



Data Quality Defined

Case Studies – Definition- Availability – Quantity
– Completeness – Correctness – Predictive
Modeling – Analytics –
Process Considerations

Profiling and Improvement

Missing Values – Time Series Data – Across Tables – Data Quality with Analytics – SAS Analytic Tools

Simulation Studies

Introduction – Predictive Modeling – Time Series Forecasting



Demo-Beispiel

THEMENSUCHE IN DOKUMENTEN UND CLUSTERING



28 Kapitel 3 Appendixe

- 59 Word-Dokumente
- "Un-supervised" Analyse




23 Kapitel5 Appendixe

- Welche Themen werden gefunden?
- In welche Cluster können die Dokumente eingeteilt werden?
- Wodurch beschreiben sich diese Cluster?



Datenintegration

BEREITSTELLUNG DER QUELLDATEN ALS WORD-DOKUMENTE




Name *	Date modified	Туре	Size
AppA_new.docx	4/17/2012 11:00 AM	Microsoft Word Doc	62 KB
AppB_new.docx	4/17/2012 11:03 AM	Microsoft Word Doc	62 KB
AppC_new.docx	4/17/2012 11:04 AM	Microsoft Word Doc	136 KB
AppD_new.docx	4/17/2012 11:07 AM	Microsoft Word Doc	73 KB
AppE_new.docx	4/19/2012 3:04 PM	Microsoft Word Doc	184 KB
AppendixA.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	284 KB
AppendixB.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	334 KB
AppendixC.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	328 KB
el chap1.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	503 KB
el chap1_new.docx	4/13/2012 11:59 AM	Microsoft Word Doc	141 KB
el chap2.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	294 KB
el chap2_new.docx	4/13/2012 12:01 PM	Microsoft Word Doc	104 KB
শ chap3.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	301 KB
el chap3_new.docx	4/13/2012 1:11 PM	Microsoft Word Doc	99 KB
el chap4.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	287 KB
enap4_new.docx	4/18/2012 9:51 AM	Microsoft Word Doc	87 KB
el chap5.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	488 KB
el chap5_new.docx	4/13/2012 1:21 PM	Microsoft Word Doc	105 KB




Text Parsing

AUTOMATISCHE SYNONYM-ERKENNUNG, STEMMING, STOP-LISTEN BERÜCKSICHTIGUNG



Erkennen von Themen

AUTOMATISCHE THEMEN-ERKENNUNG AUF BASIS ANALYTISCHER MODELLE






Detailanalyse der Themen

THEMA

eau detection,+outiler,+node,outiler detection,jmp

+simulation,+training,+training data,+response,+random
+record correctness +systematic +bias +database



Detailanalyse der Themen

THEMA

(D) (a) (b) (b)

Topic > +access,+file,+text,+relational,+relational database



PAGE 104 Data Preparation for Analytics Using SAS Chapter 13: Accessing Data PAGE 103 Part 3 Data Mart Coding and Content Chapter 13 Acces
Transposing One- and Multiple-Rows-per-Subject Data Structures 115 Chapter 15 Transposing Longitudinal Data 131 Chapter 16 Transformations of Chapter 17 Transformations of Categorical Variables 161 Chapter 18 Multiple Interval-Scaled Observations per Subject 179 Chapter 19 Multiple Catego



PAGE 38 Data Preparation for Analytics Using SAS Chapter 5: The Origin of Data PAGE 43 Part 2 Data Structures and Data Modeling Chapter 5 The Models 45 Chapter 7 Analysis Subjects and Multiple Observations 51 Chapter 8 The One-Row-per-Subject Data Mart 61 Chapter 9 The Multiple-Rows-p Data Structures for Longitudinal Analysis 77 Chapter 11 Considerations for Data Marts 89 Chapter 12 Considerations for Predictive Modeling 95 Introdu



PAGE 178 Data Preparation for Analytics Using SAS Chapter 17: Transformations of Categorical Variables PAGE 177 Chapter 17 Transformations Introduction 17.2 General Considerations for Categorical Variables 162 17.3 Derived Variables 164 17.4 Combining Categories 166 17.5 Dummy Codic Multidimensional Categorical Variables 172 17.7 Lookup Tables and External Data 176 17.1 Introduction In this chapter we will deal with transformation




40 Data Quality for Analytics Using SAS Chapter 3: Data Availability 41 Chapter 3: Data Availability 3.1 Introduction 32 3.2 General Considerations 32 Recadata availability 32 Availability and usability 32 Effort to make data available 33 Dependence on the operational process 33 Availability and alignment in tof Historic Data 34 Categorization and examples of historic data 34 The length of the history 35 Customer event histories 35 Operational systems and a



PAGE 382 Data Preparation for Analytics Using SAS Appendix B: The Power of SAS for Analytic Data Preparation PAGE 381 Appendix B The Power of 369B.1 Motivation B.2 Overview 370 B.3 Extracting Data from Source Systems 371 B.4 Changing the Data Mart Structure: Transposing 371 B.5 Data Mar Multiple-Rows-per-Subject Data Sets 372 B.6 Selected Features of the SAS Language for Data Management 375 B.7 Benefits of the SAS Macro Language

Darstellung von Term Maps

TERM-MAP FÜR DEN BEGRIFF TARGET VARIABLE






Darstellung von **Word Clouds**

WORD-CLOUD FÜR DIE DOKUMENTE

DES THEMAS 1 +score, historic, +historic snapshot, people, +snapshot



Topic-Weights pro Dokument


VERWENDUNG DER TOPIC-WEIGHTS FÜR EINE CLUSTERANALYSE

(otopic_raw1	₁ topic_raw2	⅓ topic_raw3	⊚ topic_raw4	⊚ topic_raw5	⊚ topic_raw6	⊚ topic_raw7	⊚ topic_raw8	⊚ topic_raw9	⊚ topic_raw10	⊚ topic_raw11	_DOCUMENT_	TEXT	<u></u> ⊌ URI	<u> </u>
1	0.047	0.007	0.025	0.002	0.018	0.755	001	0.038	0.092	0.022	0.001	1	298 Data Quali.	file://D:\Gerha.	AppA_r
2	0.010	0.064	0.043	005	0.014	0.065	0.025	0.015	0.056	0.012	0.014	2	304 Data Quali.	file://D:\Gerha.	AppB_n
3	0.011	0.050	0.276	009	0.021	0.049	0.018	0.047	0.015	0.035	0.032	3	306 Data Quali.	file://D:\Gerha.	AppC_n
4	0.054	0.026	0.014	053	0.018	0.097	0.023	0.363	0.048	0.015	0.010	4	318 Data Quali.	file://D:\Gerha.	AppD_r
5	0.069	0.112	0.024	0.000	0.075	0.085	0.047	0.026	0.091	002	0.002	5	PAGE 368 D.	file://D:\Gerha.	Append
6	0.048	0.039	0.049	0.005	0.086	0.069	0.021	0.034	0.149	0.248	0.043	6	PAGE 382 D.	file://D:\Gerha.	Append
7	002	043	0.040	032	0.091	0.086	0.003	0.023	0.262	0.030	0.093	7	PAGE 390 D.	file://D:\Gerha.	Append
8	0.031	0.016	0.028	0.061	0.736	0.018	0.053	0.019	0.028	0.056	0.032	8	320 Data Quali.	file://D:\Gerha.	AppE_n
9	0.032	0.026	0.037	0.071	0.098	0.028	0.283	0.033	0.013	0.039	0.031	9	PAGE 2 Dat.	. file://D:\Gerha.	chap1.r
10	0.165	0.029	0.009	0.022	0.190	0.032	0.058	0.031	0.040	0.058	0.018	10	PAGE 88 Da.	file://D:\Gerha.	chap10.
11	0.022	0.208	0.122	0.061	0.049	0.408	0.050	0.037	0.053	0.043	0.012	11	140 Data Quali.	file://D:\Gerha.	chap10
12	0.041	0.053	0.045	0.023	0.155	0.022	0.076	0.008	0.083	0.082	0.002	12	PAGE 94 Da.	file://D:\Gerha.	chap11.
13	0.110	0.090	004	0.117	0.039	0.473	0.023	0.097	0.082	0.003	0.009	13	156 Data Quali.	file://D:\Gerha.	chap11
14	0.038	0.023	0.121	0.025	0.055	0.015	0.159	0.021	0.033	0.024	009	14	PAGE 100 D.	file://D:\Gerha.	chap12
15	0.028	0.035	0.030	0.173	0.134	0.064	028	0.007	0.003	0.077	0.033	15	164 Data Quali.	file://D:\Gerha.	chap12
16	0.058	0.024	0.026	0.020	0.103	0.029	0.008	0.015	0.061	0.492	0.016	16	PAGE 104 D.	file://D:\Gerha.	chap13.
17	0.007	0.377	0.092	0.110	0.075	0.064	0.082	0.072	0.069	0.034	0.048	17	178 Data Quali.	file://D:\Gerha.	chap13
18	0.007	0.004	0.020	014	0.150	0.071	0.013	0.028	0.342	0.036	0.091	18	PAGE 130 D.	file://D:\Gerha.	chap14.
19	0.033	0.483	0.124	0.061	0.049	0.115	0.074	0.072	0.035	0.072	0.150	19	198 Data Quali.	file://D:\Gerha.	chap14
20	0.066	0.012	0.006	015	0.064	0.054	0.004	0.030	0.070	0.030	0.013	20	PAGE 138 D.	file://D:\Gerha.	chap15.
21	0.011	0.038	0.223	0.089	0.020	0.037	0.014	0.120	0.025	0.021	0.045	21	Part III: Conseq.	file://D:\Gerha.	chap15
22	0.076	0.042	0.069	0.127	0.044	0.106	0.053	0.023	0.482	0.043	0.030	22	PAGE 146 D.	file://D:\Gerha.	chap16.
22 23	0.024	0.091	0.430	0.053	0.048	0.039	0.104	0.125	0.001	0.027	0.032	23	216 Data Quali.	file://D:\Gerha.	chap16
24	0.077	0.136	0.031	0.010	0.070	0.035	0.036	0.016	0.107	0.284	027	24	PAGE 178 D.	file://D:\Gerha.	chap17.
25	0.027	0.041	0.458	0.037	0.025	0.022	0.049	0.068	0.026	0.009	0.020	25	230 Data Quali.	file://D:\Gerha.	chap17
25	0.027	0.041	0.458	0.037	0.025	0.022	0.049	0.068	0.026	0.009	0.020	25	230	Data Quali.	Data Quali file://D:\Gerha.



Cluster Analyse

CLUSTERING DER DOKUMENTE AUF BASIS DER TOPIC WEIGHTS IM SAS ENTERPRISE MINER





Cluster Analyse Ergebnisse Missing Values 10 11 Erzeugen des 14 10 11 **Analytic-Marts** Data Origin und 5 13 17 Data Management **DQ** Case **Studies Fachliche** 2 Konzepte DQ mit Analytik 13 14 und SAS **Data Quality** 16 Simulationen **Analytic Data** 8

Mart Structures

THEMATISCH ÄHNLICHE KAPITEL WERDEN AUTOMATISCH ZU

23

24

25

26

12

28

Α

CLUSTERN ZUSAMMENGEFASST

19

21

22

23

20

21

22

6

15

В

18

Е

19


20

16

18

Hauptkomponenten Analyse

SCATTER-PLOT DER KAPITEL BZGL. DER 1. UND 2. HAUPTKOMPONENTE





Text Mining

ZUSAMMENFASSUNG

- Kapitel der beiden Bücher wurden mit SAS® Contextual Analysis automatisch zu sinnvollen Clustern zusammengefasst
- Viele Einsatzgebiete für die automatische Gruppierung von Dokumenten in Unternehmen und Organisationen
- Analyse wurde mit minimaler Interaktion durch den Benutzer durchgeführt (hoher Interaktionsgrad ist möglich: SAS Code, Optionen, LITI-Rules, ...)

